

BlindDistance: assistente de navegação para pessoas com deficiência visual baseado em visão estéreo com webcams convencionais

**João Victor de Castro Carvalho¹, Mario Guerreiro Cerconvis¹,
Marco Antonio Silva da Mata¹, João Victor Gonçalves Nascimento¹**

¹Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas
Universidade Federal do ABC (UFABC)
Disciplina ESZA019 – Visão Computacional – 2026.2
Santo André – SP – Brasil

²RA 11202420287, RA 11202421459, RA 11202320279, RA 11202420821

Abstract. *This paper presents BlindDistance, an assistive navigation aid for visually impaired people built entirely from commodity hardware: two conventional USB webcams mounted on a rigid bracket with a 6–7 cm baseline and a laptop with no dedicated GPU. Depth is recovered by stereo triangulation ($Z = fB/d$) from a StereoSGBM disparity map, and the depth map is consumed by three independent alert channels: a proximity grid that beeps below 500 mm, a YOLOv8n detector cross-referenced with depth that speaks object label and distance, and a floor-drop detector based on the median depth of the lower third of the frame smoothed by an exponential moving average. The end-to-end pipeline runs at approximately 250 ms per frame (≈ 7 FPS) on an Intel i5 CPU, with a mean absolute depth error of 90 mm at 500 mm and 540 mm at 1500 mm, an average detection precision of 81.8% and a SUS score of 92.85 ($n = 7$). We report both what the system achieves and where it falls short of the 15 FPS design target, and we state explicitly which classical image processing operators are not used by the implementation, mapping each one to the functional equivalent actually present in the code.*

Resumo. *Este artigo apresenta o BlindDistance, um assistente de navegação para pessoas com deficiência visual construído inteiramente com hardware de prateleira: duas webcams USB convencionais fixadas em um suporte rígido com baseline de 6–7 cm e um notebook sem GPU dedicada. A profundidade é recuperada por triangulação estéreo ($Z = fB/d$) a partir de um mapa de disparidade StereoSGBM, e o mapa de profundidade alimenta três canais de alerta independentes: uma grade de proximidade que emite bipes abaixo de 500 mm, um detector YOLOv8n cruzado com a profundidade que fala rótulo e distância, e um detector de desnível de piso baseado na mediana da profundidade do terço inferior do quadro suavizada por média móvel exponencial. O pipeline completo executa em cerca de 250 ms por quadro (≈ 7 FPS) em uma CPU Intel i5, com erro médio absoluto de profundidade de 90 mm a 500 mm e 540 mm a 1500 mm, precisão média de detecção de 81,8% e pontuação SUS de 92,85 ($n = 7$). Relatamos tanto o que o sistema alcança quanto onde ele fica abaixo da meta de projeto de 15 FPS, e declaramos explicitamente quais operadores*

clássicos de processamento de imagens não são usados pela implementação, mapeando cada um ao equivalente funcional efetivamente presente no código.

1. Objetivos e cenário de aplicação

1.1. Objetivo geral

O objetivo geral do trabalho é projetar, implementar e avaliar experimentalmente um assistente de navegação vestível para pessoas com deficiência visual que estime a distância de obstáculos e comunique essa informação por áudio, utilizando exclusivamente visão estéreo passiva obtida de duas webcams USB convencionais, sem sensor de profundidade dedicado, sem LiDAR e sem GPU. A restrição de hardware define o problema: câmeras de profundidade ativas resolvem a estimativa de distância de forma mais robusta, mas custam de cinco a vinte vezes mais e falham sob incidência solar direta. O sistema assume uma estimativa mais ruidosa em troca de reprodutibilidade.

1.2. Objetivos específicos

1. Calibrar geometricamente um par estéreo de webcams não sincronizadas, obtendo parâmetros intrínsecos, extrínsecos e mapas de retificação pré-computados que permitam aplicação em tempo real.
2. Produzir, em fluxo contínuo, um mapa de profundidade métrico em milímetros a partir do mapa de disparidade, com faixa útil declarada e erro caracterizado experimentalmente.
3. Detectar e classificar obstáculos relevantes para navegação assistiva, cruzando a caixa delimitadora de cada detecção com o mapa de profundidade para obter a distância física do objeto reconhecido.
4. Detectar desníveis de piso (degraus descendentes, buracos, escadas) diretamente no mapa de profundidade, sem depender da rede neural.
5. Comunicar todos os alertas por áudio não bloqueante, com prioridade, supressão de repetição e tolerância a falhas do motor de síntese de voz.

1.3. Critérios de aceitação

O cenário de aplicação foi delimitado por critérios de aceitação (CA) verificáveis, fixados antes da implementação:

- **CA1 – faixa operacional.** O sistema deve produzir leituras de distância utilizáveis entre 0,5 m e 3,0 m. Abaixo de 0,5 m a disparidade excede a faixa de busca configurada e a região aparece como vazio; acima de 3,0 m o erro quadrático da triangulação (Seção 3.1) já não permite decisão de trajetória.
- **CA2 – geometria de montagem.** *Baseline* fixa de 6 a 7 cm, câmeras coplanares, montagem rígida na altura do tórax, com o eixo óptico levemente inclinado para baixo para que o terço inferior do quadro contenha o piso a cerca de 1,5 m à frente dos pés.
- **CA3 – complementaridade.** O dispositivo é complementar à bengala longa e ao cão-guia, nunca substituto. A bengala cobre de forma confiável a faixa de 0 a 0,5 m, exatamente a zona cega do par estéreo; o BlindDistance cobre a faixa de 0,5 a 3,0 m, à qual a bengala não alcança. Essa divisão de faixas é o argumento central de projeto e foi comunicada a todos os participantes dos testes.

- **CA4 – latência percebida.** O intervalo entre a entrada de um obstáculo na cena e o início da locução correspondente deve permanecer abaixo de 1 s em marcha lenta.

Ficam explicitamente **fora** do escopo: reconhecimento de texto e sinalização, identificação de faces, travessia de vias com semáforo, navegação com mapa ou GPS, operação sob chuva e uso noturno sem iluminação artificial. Nenhuma dessas funções foi implementada e nenhuma foi avaliada.

2. Entrevistas empáticas, motivação e justificativa

2.1. Motivação

A motivação do projeto é a distância entre o volume da população com deficiência visual no Brasil e a oferta de tecnologia assistiva acessível para mobilidade. O Censo Demográfico do IBGE registra deficiência visual como a limitação mais frequente entre as deficiências declaradas [IBGE CHER]; a edição do Censo utilizada como referência e o número exato citado são [PREENCHER]. O ponto que interessa ao projeto é qualitativo e independe da precisão do número: a bengala longa, tecnologia dominante e de baixo custo, é um sensor de contato — ela informa o que já está ao alcance do braço, e não o que se aproxima. Toda a faixa entre meio metro e três metros, onde estão as decisões de trajetória, permanece inacessível.

2.2. Roteiro das entrevistas

Foram conduzidas entrevistas empáticas semiestruturadas antes de qualquer decisão de implementação, organizadas em quatro blocos: (i) rotina de deslocamento e trajetos habituais; (ii) episódios concretos de quase acidente e o que os causou; (iii) tecnologias assistivas já utilizadas, incluindo as abandonadas e o motivo do abandono; (iv) reação a um protótipo conceitual de alerta sonoro, com atenção especial ao incômodo causado pela ocupação do canal auditivo.

O número de entrevistados, o perfil demográfico e clínico de cada um (idade, grau e tempo de perda visual, uso de bengala ou cão-guia), a duração e o formato das entrevistas (presencial ou remoto) e o procedimento de consentimento informado são [PREENCHER]. Registramos essa lacuna explicitamente em vez de estimá-la: os achados da Tabela 1 são qualitativos e orientaram decisões de projeto, mas não sustentam nenhuma afirmação estatística sobre a população.

2.3. Dos achados às decisões de projeto

A Tabela 1 vincula cada achado das entrevistas a uma decisão de projeto rastreável no código, o que torna o requisito verificável em vez de retórico.

2.4. Justificativa

A justificativa social é o custo: o sistema usa apenas duas webcams, um suporte rígido, um computador de uso geral e alto-falantes. A didática é a cobertura do programa da disciplina — calibração, geometria epipolar, retificação, casamento estéreo, filtragem espacial, pseudo-cor, análise de regiões e inferência convolucional em uma única aplicação integrada, com o custo computacional de cada etapa disputando um orçamento fixo de latência.

Tabela 1. Achados das entrevistas empáticas e decisões de projeto correspondentes.

Achado da entrevista	Decisão de projeto
Obstáculos na altura do tronco e da cabeça (galhos, placas, portas entreabertas) não são cobertos pela bengala	Montagem na altura do tórax, com o campo de visão cobrindo do piso à cabeça, e alerta por bipe para qualquer ponto da grade abaixo de 500 mm
Degraus descendentes e buracos são o risco mais temido	Canal de detecção de desnível independente da rede neural, operando direto no mapa de profundidade do terço inferior do quadro
Fones que bloqueiam a audição são rejeitados, porque a audição é o principal sensor remanescente	Alertas curtos e esparsos: bipe de 80 ms com intervalo mínimo de 1,5 s, locução com <i>cool-down</i> de 3 s por objeto e bipes silenciados durante a fala
Alarmes constantes levam ao abandono do dispositivo	Limiar de proximidade em 500 mm e <i>whitelist</i> de 30 classes COCO relevantes, em vez das 80 classes do modelo
Saber <i>o que</i> está à frente muda a reação, não apenas <i>que há</i> algo	Locução do rótulo em português seguido da distância, e não somente um tom proporcional à distância

3. Fundamentação teórica

3.1. Aquisição e geometria estéreo

A calibração de cada câmera segue o método de [Zhang 2000], que estima matriz intrínseca K e coeficientes de distorção a partir de múltiplas vistas de um padrão planar. Com um tabuleiro de 8×6 cantos internos e quadrados de 30 mm, cada imagem contribui 48 correspondências 2D–3D, e a calibração resolve

$$\min_{K, \text{dist}, R_i, t_i} \sum_{i=1}^N \sum_{j=1}^{48} \|\mathbf{p}_{ij} - \hat{\mathbf{p}}(K, \text{dist}, R_i, t_i, \mathbf{P}_j)\|^2, \quad (1)$$

onde $\mathbf{p}_{ij}$ é o canto detectado com refinamento sub-pixel e $\hat{\mathbf{p}}$ sua reprojeção. Com $N = 27$ pares, o sistema é largamente sobredeterminado.

A calibração estéreo estima a pose relativa $\mathbf{p}_R = R \mathbf{p}_L + T$ entre as câmeras, sendo T_x a *baseline*. A retificação aplica a ambas as imagens uma transformação que torna as linhas epipolares horizontais e coincidentes em linha, reduzindo a busca por correspondências de duas dimensões a uma. Como os mapas de remapeamento são pré-computados uma única vez, a retificação em tempo real custa apenas duas interpolações bilineares por quadro.

Da semelhança de triângulos na configuração retificada decorre a relação fundamental

$$Z = \frac{f \cdot B}{d}, \quad (2)$$

com Z em milímetros, f em pixels, B em milímetros e d a disparidade em pixels. Derivando em relação a d obtém-se a propriedade que domina todo o comportamento do sistema:

$$\Delta Z \approx \frac{Z^2}{f \cdot B} \Delta d. \quad (3)$$

O erro cresce com o *quadrado* da distância. Com $f \approx 650$ px, $B \approx 65$ mm e $\Delta d \approx 0,3$ px — típico de casamento sub-pixel em webcams USB —, o erro passa de menos de 10 cm a meio metro para mais de meio metro a um metro e meio. Nenhum ajuste de parâmetro contorna isso: é geometria. Daí o CA1 limitar a faixa a 3,0 m e os alertas críticos serem disparados apenas abaixo de 1,0 m.

3.2. Casamento estéreo e filtragem espacial

O casamento é feito pelo algoritmo *Semi-Global Block Matching* [Hirschmüller 2008], que minimiza uma energia composta por um termo de dados e dois termos de suavidade, agregados ao longo de múltiplas direções unidimensionais — formulação também discutida em [Szeliski 2022]:

$$E(D) = \sum_{\mathbf{p}} \left(C(\mathbf{p}, D_{\mathbf{p}}) + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_1 [|D_{\mathbf{p}} - D_{\mathbf{q}}| = 1] + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_2 [|D_{\mathbf{p}} - D_{\mathbf{q}}| > 1] \right). \quad (4)$$

As penalidades $P_1 = 8 \cdot 3 \cdot 9^2 = 1944$ e $P_2 = 32 \cdot 3 \cdot 9^2 = 7776$ desempenham, no domínio da disparidade, o papel que um filtro de suavização desempenha no domínio da intensidade: P_1 tolera variações de um nível — superfícies inclinadas — enquanto P_2 penaliza descontinuidades fortes sem proibi-las, preservando bordas de objetos. Quando a extensão `opencv-contrib` está disponível, aplica-se adicionalmente o filtro de mínimos quadrados ponderados [Min et al. 2014] com $\lambda = 8000$ e $\sigma_{\text{cor}} = 1,5$, que propaga disparidade para regiões sem textura usando a imagem colorida como guia de bordas. Trata-se, formalmente, de uma filtragem no domínio espacial guiada por conteúdo — o análogo, sensível a bordas, da convolução com um núcleo gaussiano [Gonzalez and Woods 2018].

3.3. Histograma, cores e limiarização

O casamento opera sobre as imagens convertidas para nível de cinza pela transformação $\text{BGR} \rightarrow \text{gray}$ ponderada, que preserva o gradiente de luminância — a informação de que o SGBM depende — e descarta a crominância, reduzindo o custo por quadro. A visualização de profundidade aplica um escalonamento linear da faixa de 0 a 4000 mm para 0–255 seguido do mapa de cores `COLORMAP_JET`, transformação de pseudo-cor cujo único propósito é a inspeção humana durante a depuração; nenhuma decisão do sistema depende dela.

A limiarização é o ponto em que a implementação se afasta deliberadamente do roteiro clássico. O método de Otsu [Otsu 1979] escolhe o limiar que maximiza a variância entre classes de um histograma bimodal. O mapa de profundidade de uma cena de navegação não é bimodal: é multimodal e não estacionário, com um modo por superfície visível e uma massa em zero correspondente aos pixels sem correspondência válida. Um

limiar global sobre esse histograma separaria *alguma* coisa, mas não a fronteira que interessa. O sistema usa, em lugar disso, limiares métricos absolutos (500 mm para o bipe, 1000 mm para a locução de cautela), que são diretamente interpretáveis em termos de segurança, e um limiar *adaptativo* para o piso, no qual a referência é recalculada continuamente pela mediana filtrada por média móvel exponencial (Seção 4.3). O papel funcional da limiarização adaptativa está presente; a implementação canônica de Otsu, não.

3.4. Morfologia, regiões e declaração de transparência

Duas operações do código cumprem papéis morfológicos sem chamar operadores morfológicos: o filtro de *speckle* do SGBM (`speckleWindowSize = 100`, `speckleRange = 32`), que elimina componentes conexas pequenas e inconsistentes do mapa de disparidade — o efeito de uma abertura morfológica sobre regiões de disparidade — e a razão entre a área suspeita e a área total da região de piso ($\rho_{\text{susp}} > 0,25$), que é um descritor de região no sentido de [Gonzalez and Woods 2018], usado como critério de decisão em lugar de uma contagem de contornos.

Por transparência, declaramos explicitamente: o código-fonte **não** chama `cv2.GaussianBlur`, **não** chama `cv2.threshold` com `THRESH_OTSU`, **não** chama `cv2.morphologyEx` ou `cv2.erode/cv2.dilate` e **não** chama `cv2.findContours`. Os tópicos correspondentes do roteiro entram neste artigo como *equivalentes funcionais*, resumidos adiante na Tabela 6, e como trabalho futuro: a substituição do filtro de *speckle* por uma abertura explícita e da razão de área por análise de componentes conexas com `findContours` permitiria não apenas detectar *que* há um desnível, mas delimitar *onde* ele está e estimar sua extensão — informação hoje ausente do alerta falado.

4. Materiais e métodos

4.1. Tecnologias e hardware

A implementação é em Python 3.12, com OpenCV ≥ 4.10 [Bradski and Kaehler 2008] para captura, calibração, retificação e disparidade; `ultralytics` ≥ 8.4 (YOLOv8 Nano, 3,2 milhões de parâmetros) [Jocher et al. 2023] para detecção; `pyttsx3` para síntese de voz *offline* e `pygame` para geração dos bipes. O hardware de teste é um notebook com processador Intel i5 de 7ª geração, 8 GB de RAM e **sem GPU dedicada**, duas webcams USB operando a 640×480 pixels e um suporte rígido com *baseline* de 60 a 70 mm. Todas as medidas de latência da Seção 5 referem-se a essa configuração; em máquina com GPU o bloco de detecção cairia em uma ordem de grandeza, mas o compromisso que o artigo documenta é o do hardware mínimo.

4.2. Arquitetura

A Figura 1 apresenta o diagrama de blocos funcional. Duas características da arquitetura merecem destaque. Primeiro, a captura, a retificação e o cálculo de disparidade executam em uma *thread* dedicada que publica o último mapa de profundidade em um par de *buffers* protegido por *lock*; o laço principal consome sempre o quadro mais recente e nunca bloqueia esperando a câmera. Segundo, dos três canais de alerta, dois — grade de proximidade e detecção de desnível — operam *diretamente* sobre o mapa de profundidade, sem passar pela rede neural. Essa separação é uma decisão de segurança: as funções críticas continuam operantes diante de qualquer objeto, inclusive dos que não pertencem às 80 classes do COCO, e sobrevivem a uma falha do módulo de inferência.




Figura 1. Diagrama de blocos funcional do BlindDistance. Os canais de grade de proximidade e de desnível de piso derivam apenas do mapa de profundidade.

4.3. Implementação

Calibração. O utilitário `stereo_calibration.py` coleta 27 pares simultâneos do tabuleiro 8×6 de 30 mm, detecta os cantos com `findChessboardCorners` e os refina com `cornerSubPix` em janelas 11×11 (critério: 30 iterações ou erro $< 0,001$), calibra cada câmera individualmente, executa `stereoCalibrate` e `stereoRectify` e persiste R , T , Q e os quatro mapas de remapeamento em um arquivo XML. A distância focal é lida de $Q[2, 3]$ e a *baseline* de $|1/Q[3, 2]|$, com recurso a $|T_x|$ caso $Q[3, 2]$ seja nulo.

Disparidade e profundidade. O `StereoSGBM` é configurado com `numDisparities = 128`, `blockSize = 9`, `displ2MaxDiff = 1`, `uniquenessRatio = 10`, `preFilterCap = 63` e modo `SGBM_3WAY`, variante que agrega custo em três direções em vez de oito, reduzindo o tempo por quadro em troca de leve perda de qualidade — escolha ditada pelo orçamento de latência. A saída inteira é dividida por 16 para recuperar a parte sub-pixel, convertida em milímetros por $Z = fB/d$ apenas onde $d > 0$, e valores acima de 10 m são zerados como inválidos. O resultado é um mapa `uint16` de profundidade.

Deteção com distância. O `YOLOv8n` processa a imagem esquerda retificada, descarta detecções com confiança inferior a 0,5 e filtra as classes por uma *whitelist* de 30 categorias COCO relevantes para navegação (pessoa, veículos, animais, mobiliário urbano, mobiliário interno e objetos portáteis). Para cada detecção sobrevivente, a distância é a mediana dos valores válidos de um bloco de 11×11 pixels centrado na caixa. A mediana, e não a média, é essencial: um único pixel espúrio de disparidade alta produziria uma leitura de poucos centímetros e um alerta de emergência falso.

Grade de proximidade. O mapa de profundidade é subamostrado em uma grade de passo 20 px em ambos os eixos, ignorando as 40 primeiras linhas e as 20 primeiras

colunas, onde a retificação introduz artefatos de borda. Se o menor valor válido da grade fica abaixo de 500 mm, dispara-se um bipe de 600 Hz e 80 ms.

Desnível de piso. Sobre o terço inferior do quadro (a partir de 67% da altura), consideram-se válidos os valores entre 0 e 6000 mm e calcula-se sua mediana m_t . A referência de piso é atualizada por média móvel exponencial,

$$b_t = \alpha m_t + (1 - \alpha) b_{t-1}, \quad \alpha = 0,05, \quad (5)$$

constante de tempo deliberadamente longa (cerca de 20 quadros, ≈ 3 s a 7 FPS) para que o piso normal defina a referência e um degrau não a contamine antes de ser detectado. Contam-se então os pixels da região de piso com $Z > 1,5 b_t$ (o piso “recuou”) somados aos pixels com $Z = 0$ (não houve retorno algum); se essa soma excede 25% da região, emite-se o alerta falado “Atenção! Desnível à frente”. Incluir os pixels sem retorno é o que permite detectar o caso mais perigoso, o vão em que não existe superfície a ser medida.

Áudio. A fila de mensagens é limitada a três elementos e descarta o anúncio mais antigo quando cheia, de modo que o usuário sempre ouça a informação mais recente. Existe *cooldown* global de 3 s e *cooldown* por objeto, para que “pessoa” não silencie “cadeira”. Os bipes têm intervalo mínimo de 1,5 s e são suprimidos durante a fala. O motor de síntese é instanciado *dentro* da *thread* de áudio, porque em Windows o objeto COM do SAPI5 só é válido na *thread* que o criou, e há uma cadeia de *backends* com *fallback* (pyttsx3 $\rightarrow$ SAPI5 direto $\rightarrow$ PowerShell System.Speech $\rightarrow$ espeak), com preferência automática por vozes em português. Um *watchdog* com tempo limite de 20 s marca como falho o *backend* que travou e promove o seguinte, comportamento incorporado após o defeito relatado na Seção 8.

4.4. Compatibilidade e processamento de vídeo

O mesmo código executa em Linux e Windows sem ramificação no laço principal: toda a diferença de plataforma está na cadeia de *backends* de TTS. Além da operação ao vivo, `data_recorder.py` grava quadros anotados a 2 FPS com etiqueta selecionável pelo teclado e `debug_floor_drop.py` reprocesa gravações, o que permitiu calibrar α e o limiar de razão sem repetir o posicionamento no topo de uma escada.

5. Análise de desempenho

5.1. Latência e taxa de quadros

A latência foi medida com `time.perf_counter()` em torno de cada bloco do laço principal, com contagem temporal de quadros para a taxa ponta a ponta. A Tabela 2 apresenta o resultado.

O resultado fica abaixo da meta de 15 FPS, e a Tabela 2 mostra por quê: YO-LOv8n em CPU consome metade do orçamento e o SGBM um terço; os demais blocos somam menos de 15 ms, de modo que otimizá-los é irrelevante. Duas consequências: 7 FPS bastam para marcha lenta em ambiente interno — o regime dos testes — mas não para caminhada normal, em que a 1,2 m/s o usuário percorre 17 cm entre quadros; e, como grade e desnível não dependem da inferência, amostrar o YOLO a cada segundo ou terceiro quadro elevaria os alertas críticos a cerca de 11 FPS sem trocar de hardware. Essa é a otimização de maior retorno e não foi implementada nesta versão.

Tabela 2. Latência média por bloco do *pipeline* (Intel i5 7ª geração, 8 GB, sem GPU, 640×480).

Bloco	Tempo por quadro	Fração do total
Captura + retificação (2 câmeras)	8–9 ms	≈ 3%
Conversão para nível de cinza	1–2 ms	≈ 1%
StereoSGBM (128 disparidades, 3WAY)	80–90 ms	≈ 34%
YOLOv8n (PyTorch, CPU)	≈ 127 ms	≈ 51%
Grade + alertas + OSD	≈ 3 ms	≈ 1%
Total por quadro	≈ 250 ms	100%
Taxa ponta a ponta		≈ 7 FPS

5.2. Acurácia da leitura de objetos

A acurácia de detecção foi avaliada por classe, com contagem manual de verdadeiros positivos, falsos positivos e falsos negativos sobre as sequências de teste, calculando precisão $= VP/(VP + FP)$, revocação $= VP/(VP + FN)$ e $F_1 = 2PR/(P + R)$. Os resultados agregados são: *person* 92%/89%/0,90; *car* 88%/82%/0,85; *dog/cat* 82%/72%/0,77; *cell phone* 65%/40%/0,50; com médias de **81,8%** de precisão, **70,8%** de revocação e F_1 médio de **0,76**. A matriz de confusão agregada apresenta $VP \approx 63$, $FP \approx 5$, $FN \approx 37$ e $VN \approx 95$.

A leitura é assimétrica. A precisão de 81,8% significa que o sistema raramente mente sobre a presença de um obstáculo, o que preserva a confiança do usuário — condição de uso continuado, como o item 9 do questionário confirma. A revocação de 70,8% significa que três em cada dez objetos não são anunciados, inaceitável se a detecção fosse o único canal; é aqui que a redundância paga, pois um objeto desconhecido ainda gera bipe abaixo de 500 mm. O pior caso é *cell phone* ($F_1 = 0,50$): objetos pequenos a mais de 1 m ocupam poucos pixels em 640×480 e o bloco de amostragem 11×11 pode cair no fundo, produzindo distância errada mesmo com classificação correta.

5.3. Erro de profundidade

O erro foi caracterizado posicionando um alvo plano a distâncias medidas com fita métrica e comparando com a leitura do sistema, com $MAE = \frac{1}{N} \sum |Z_i - \hat{Z}_i|$ e $MAPE = \frac{1}{N} \sum |Z_i - \hat{Z}_i|/Z_i \times 100\%$. A Tabela 3 apresenta o resultado e o compara com a previsão teórica da Equação (3).

Tabela 3. Erro de estimativa de profundidade e comparação com o modelo teórico $\Delta Z \approx Z^2/(fB) \Delta d$.

Distância real	ΔZ teórico	MAE	MAPE	Classificação
500 mm	± 90 mm	≈ 90 mm	≈ 18%	Bom
1000 mm	± 270 mm	≈ 270 mm	≈ 27%	Aceitável
1500 mm	± 540 mm	≈ 540 mm	≈ 36%	Aceitável

A concordância entre erro medido e previsto confirma que o desempenho é limitado pela geometria, não por defeito de implementação: o MAE triplica quando a distância dobra. A implicação é direta: 27% de erro a 1 m permitem decidir se um obstáculo

está “perto” ou “longe”, mas não sustentam o anúncio de décimos de metro — imprecisão que reconhecemos e que faixas verbais corrigiriam. O RMSE por faixa completa o quadro: 50–80 mm entre 0,5 e 1,0 m, 100–200 mm entre 1,0 e 2,0 m e 250–450 mm entre 2,0 e 3,0 m. Na inspeção das imagens de calibração identificamos quatro fatores de degradação: tabuleiro segurado à mão (tremor e não planaridade), reflexos da iluminação interna, quantidade adequada de pares (27, acima do mínimo usual de 15 a 20) e variação real de ângulo e distância, esta favorável à robustez. Fixar o tabuleiro em superfície rígida é o caminho de menor esforço para reduzir o erro residual.

5.4. Influência da iluminação

O SGBM depende de textura local. Para quantificar essa dependência sem verdade de campo densa, adotamos a densidade de profundidade válida

$$\rho = \frac{\#\{(x, y) : Z(x, y) > 0\}}{\#\{(x, y)\}}, \quad (6)$$

fração de pixels com correspondência válida em um quadro. ρ cai acentuadamente em paredes lisas monocromáticas (sem gradiente a casar), contraluz (saturação do sensor) e iluminação fraca (ruído dominante). O mecanismo importa porque a queda de ρ não produz leitura errada, mas ausência de leitura — exatamente o padrão que o detector de desnível interpreta como vão. Daí o falso positivo da Seção 8 e a necessidade do limiar de razão de 25% em vez de um limiar sobre pixels isolados.

6. Laboratório experimental

6.1. Preparação

Cada sessão seguiu o mesmo protocolo: verificação da montagem e conexão das webcams; verificação de volume e clareza do áudio; ambiente com pelo menos 3 m livres, objetos comuns (cadeira, mochila, garrafa, copo) e paredes planas; e confirmação de que a calibração vigente corresponde ao suporte em uso — qualquer deslocamento das câmeras invalida a escala métrica de todas as leituras. O sistema inicia com `python main.py`, com `r` para gravação, `1–5` para etiquetar a cena e `q` para encerrar.

6.2. Teste A – alerta de proximidade

Objetivo: verificar o disparo do bipe diante de uma barreira plana. Procedimento: aproximação lenta de uma parede lisa a partir de 2 m. Resultado esperado: início dos bipes ao cruzar o limiar de proximidade e cessação ao afastamento. Observou-se comportamento correto em paredes com alguma textura (pintura fosca, rodapé, quadro) e comportamento degradado em parede branca perfeitamente lisa sob iluminação difusa, caso em que a densidade válida ρ na região central cai e o bipe atrasa. Essa é a limitação mais relevante do sistema para uso interno e está registrada na Tabela 5.

6.3. Teste B – identificação com distância

Objetivo: verificar o anúncio falado de rótulo e distância. Procedimento: objeto comum posicionado entre 1 e 2 m, câmeras apontadas diretamente para ele. Resultado esperado: locução do tipo “cadeira a 1,5 metros”. Observou-se locução correta e estável para pessoa e cadeira; para objetos pequenos, a identificação frequentemente ocorre sem leitura de distância válida (`distance_mm = 0`), caso em que o sistema anuncia apenas o rótulo seguido de “à frente” — comportamento intencional, preferível ao silêncio ou a uma distância inventada.

6.4. Teste C – desnível

Objetivo: verificar o alerta de risco de queda. Procedimento: posicionamento seguro no topo de um lance de escada descendente, com as câmeras levemente inclinadas para baixo, a distância que não ofereça risco ao operador. Resultado esperado: alerta falado ao surgir o vão no terço inferior do quadro. Observou-se detecção consistente da escada descendente e — na versão anterior ao ajuste da constante α e do limiar de razão — falsos positivos ao atravessar piso escuro e sem textura, comportamento eliminado com os valores atuais ($\alpha = 0,05$, razão de 25%).

6.5. Questionário

Após os três testes, cada participante respondeu ao questionário de 11 itens em escala de 1 a 5 analisado na Seção 7. O questionário foi aplicado imediatamente após a sessão, sem intervalo, e os itens foram lidos em voz alta pelo operador quando necessário.

7. Enquete subjetiva e teste de campo

7.1. Instrumento e resultados

O instrumento é uma adaptação da *System Usability Scale* [Brooke 1996], com os dez itens canônicos — ímpares de polaridade positiva, pares de polaridade negativa — mais um item adicional sobre interatividade percebida. A escala vai de 1 (discordo totalmente) a 5 (concordo totalmente) e foram obtidas $n = 7$ respostas. A Tabela 4 traz as médias.

Tabela 4. Médias do questionário de usabilidade ($n = 7$; escala de 1 a 5).

Item	Média	Leitura
1. Gostaria de usar o sistema com frequência	5,00	Intenção de uso unânime
2. Achei o sistema desnecessariamente complexo	1,00	Percebido como direto
3. Achei o sistema fácil de usar	4,71	Fácil para a quase totalidade
4. Precisaria de suporte de pessoa técnica	1,57	Autonomia alta
5. As funções foram bem integradas	5,00	Integração percebida
6. Havia inconsistências no sistema	1,43	Poucas inconsistências
7. A maioria aprenderia a usar rapidamente	5,00	Curva de aprendizado curta
8. Achei o sistema complicado de usar	1,43	Pouca complicação
9. Senti-me confiante ao usar o sistema	5,00	Confiança máxima
10. Precisei aprender muito antes de usar	2,14	Requer alguma orientação
11. O sistema é interativo (item extra)	5,00	Alta interatividade

7.2. Cálculo do escore SUS

Aplicando a fórmula canônica aos dez primeiros itens,

$$SUS = 2,5 \times \left[\sum_{\text{ímpares}} (x_i - 1) + \sum_{\text{pares}} (5 - x_i) \right], \quad (7)$$

tem-se para os itens ímpares $(5 - 1) + (4,71 - 1) + (5 - 1) + (5 - 1) + (5 - 1) = 19,71$ e para os pares $(5 - 1) + (5 - 1,57) + (5 - 1,43) + (5 - 1,43) + (5 - 2,14) = 17,43$, resultando em

$$\text{SUS} = 2,5 \times (19,71 + 17,43) = 2,5 \times 37,14 = \mathbf{92,85}. \quad (8)$$

O item 11 fica fora da fórmula, por não pertencer ao instrumento original. Na escala de referência, 68 é a média de sistemas avaliados e valores acima de 80 correspondem ao quartil superior; 92,85 situa-se na faixa mais alta.

7.3. Leitura qualitativa e ressalva metodológica

Agrupando os itens por dimensão: eficácia (itens 1, 5 e 9) atinge 5,00/5,00; eficiência (3 e 7), 4,86/5,00; satisfação (2, 4, 6, 8 e 10, invertidos), 4,49/5,00; e interatividade (item 11), 5,00/5,00. O item de menor desempenho relativo é o 10 (2,14): parte dos participantes sentiu falta de orientação inicial, o que sugere um tutorial em áudio na primeira execução — melhoria de baixo custo e alto retorno percebido. É notável que a dimensão de eficácia receba nota máxima enquanto as métricas objetivas registram 7 FPS e revocação de 70,8%: a percepção do usuário é dominada pelo fato de que os alertas *ocorrem* e são compreensíveis, não pela taxa de quadros.

A ressalva metodológica é parte do resultado, não nota de rodapé. Com $n = 7$, um respondente desloca qualquer média em cerca de 0,14 ponto e nenhum intervalo de confiança útil pode ser construído. Os testes foram conduzidos pela própria equipe desenvolvedora, condição que favorece o efeito de cortesia, e o padrão de respostas — cinco itens em 5,00 exatos e um em 1,00 — indica ausência de discordância interna, compatível tanto com um sistema muito bom quanto com aquiescência. O perfil dos sete participantes, o local e a duração das sessões de campo e o procedimento de consentimento são [PREENCHER]. O valor 92,85 é, portanto, indício favorável de aceitação em condição controlada, não medida generalizável: uma avaliação conclusiva exigiria avaliador independente, amostra majoritariamente composta por pessoas com deficiência visual e coleta em ambiente não controlado.

8. Desafios encontrados e soluções adotadas

A Tabela 5 consolida os defeitos e limitações efetivamente enfrentados durante o desenvolvimento e a solução adotada em cada caso. Todos os itens correspondem a alterações presentes no código.

9. Conclusão

9.1. Pontos positivos

O trabalho demonstra que um assistente com três canais independentes de alerta — proximidade, identificação com distância e desnível de piso — é construtível com duas webcams convencionais e um notebook sem GPU. O principal acerto de projeto é separar os canais que dependem da rede neural dos que dependem apenas do mapa de profundidade, mantendo as funções críticas operantes diante de objetos fora do vocabulário do COCO e de falhas da inferência. O erro de profundidade medido coincide com a previsão teórica em toda a faixa, o que dá confiança nos parâmetros da calibração, e o escore SUS de 92,85 indica boa aceitação em condição controlada.

Tabela 5. Desafios encontrados durante o desenvolvimento e soluções adotadas.

Desafio	Solução adotada
Superfícies lisas e sem textura (paredes brancas) não produzem correspondência e geram vazios no mapa de profundidade	Filtro WLS quando <code>opencv-contrib</code> está presente, filtro de <i>speckle</i> sempre ativo e limiar de razão de área em vez de decisão por pixel isolado
Classes semanticamente próximas (copo/garrafa, cadeira/sofá) alternam entre quadros e geram locução instável	<i>Cooldown</i> de 3 s por objeto com chave própria e <i>whitelist</i> de 30 classes, reduzindo alternância percebida
Iluminação fraca e contraluz derrubam a densidade válida ρ e provocam falso desnível	Constante da média móvel exponencial em $\alpha = 0,05$ e limiar de razão de área em 25%, incluindo pixels sem retorno na contagem
Compatibilidade de sistema operacional: <code>pyttsx3</code> depende de COM em Windows e de <code>espeak</code> em Linux	Cadeia de <i>backends</i> com <i>fallback</i> automático e criação do motor dentro da <i>thread</i> de áudio
Travamento do motor de voz após a primeira locução	Encerramento explícito do laço do <code>pyttsx3</code> e <i>watchdog</i> de 20 s que marca o <i>backend</i> como falho e promove o próximo
Inversão esquerda/direita das câmeras invalida a disparidade e produz profundidade nula em todo o quadro	Opção <code>--swap</code> no utilitário de calibração e verificação visual de retificação (tecla <code>v</code>) antes de cada sessão
Bipes contínuos sobrepondo a fala e tornando ambos incompreensíveis	Intervalo mínimo de 1,5 s entre bipes e supressão de bipes enquanto há locução em curso

9.2. Limitações

As limitações são de três naturezas. *Físicas*: o erro cresce quadraticamente com a distância, limitando o uso confiável a 3 m, e a estimativa depende de textura, degradando-se em paredes lisas e em contraluz. *Computacionais*: 7 FPS ficam abaixo da meta de 15 FPS, com 85% do orçamento consumido por SGBM e YOLO. *Metodológicas*: com $n = 7$, com teste conduzido pela própria equipe e com o perfil dos participantes em [PREENCHER], a avaliação subjetiva não é generalizável, e as métricas de detecção foram obtidas em sequências próprias, não em conjunto de avaliação padronizado.

9.3. Melhorias futuras

Em ordem de retorno estimado: (i) desacoplar a cadência do YOLO da cadência dos canais críticos, elevando a frequência dos alertas de proximidade e desnível para perto de 11 FPS sem trocar de hardware; (ii) exportar o detector para ONNX ou NCNN com quantização em inteiros, atacando os 127 ms que dominam o orçamento; (iii) recalibrar com o tabuleiro fixado em superfície rígida e avaliar `numDisparities = 96` com *baseline* maior; (iv) substituir o filtro de *speckle* por abertura morfológica explícita e a razão de área por análise de componentes conexas com `findContours`, o que permitiria informar a posição e a extensão do desnível, e não apenas sua presença; (v) trocar o anúncio de distância decimal por faixas verbais coerentes com a incerteza medida; (vi) incluir tutorial em áudio na primeira execução, atacando o item 10 do questionário; e (vii) reavaliar com amostra ampliada, avaliador independente e maioria de participantes com deficiência visual.

9.4. Mapeamento com a bibliografia da disciplina

A Tabela 6 relaciona os tópicos canônicos de [Gonzalez and Woods 2018] com o que a implementação efetivamente contém, mantendo a distinção entre operador canônico e equivalente funcional declarada na Seção 3.4.

Tabela 6. Tópicos de [Gonzalez and Woods 2018] e sua realização na implementação.

Tópico (Gonzalez & Woods, 4. ^a ed.)	Realização no BlindDistance
Cap. 2 – Amostragem, quantização e geometria de aquisição	Calibração de Zhang com 27 pares 8×6 , retificação epipolar por mapas pré-computados
Cap. 3 – Transformações de intensidade e filtragem espacial	Equivalente funcional: penalidades P_1/P_2 do SGBM e filtro WLS guiado por bordas (sem GaussianBlur)
Cap. 3 – Limiarização	Equivalente funcional: limiares métricos absolutos (500/1000 mm) e limiar adaptativo por mediana com média móvel exponencial (sem Otsu)
Cap. 6 – Processamento de imagens em cores	Conversão BGR→cinza para casamento e pseudo-cor COLORMAP_JET para inspeção do mapa de profundidade
Cap. 9 – Morfologia	Equivalente funcional: filtro de <i>speckle</i> sobre componentes conexas de disparidade (sem morphologyEx)
Cap. 10/11 – Segmentação, regiões e descritores	Equivalente funcional: razão entre área suspeita e área total da região de piso (sem findContours)
Cap. 12 – Reconhecimento de padrões e aprendizado profundo	YOLOv8n com <i>whitelist</i> de 30 classes COCO e limiar de confiança de 0,5, cruzado com o mapa de profundidade

9.5. Considerações finais

O BlindDistance não é um produto, mas um protótipo cujo valor está em tornar explícitos os compromissos de uma solução de baixo custo. Os números favoráveis (precisão de 81,8%, 90 mm de erro a meio metro, SUS de 92,85) e os desfavoráveis (7 FPS contra 15 pretendidos, revocação de 70,8%, $n = 7$ com efeito de cortesia) foram apresentados com a mesma metodologia, porque é essa a informação que orienta a próxima iteração. As lacunas **[PREENCHER]** correspondem a dados não coletados de forma recuperável e permanecem assinaladas em lugar de estimadas.

Referências

- Bradski, G. and Kaehler, A. (2008). *Learning OpenCV: Computer Vision with the OpenCV Library*. O'Reilly Media, Sebastopol, CA.
- Brooke, J. (1996). Sus: A quick and dirty usability scale. In Jordan, P. W., Thomas, B., Weerdmeester, B. A., and McClelland, I. L., editors, *Usability Evaluation in Industry*, pages 189–194. Taylor & Francis, London.

- Gonzalez, R. C. and Woods, R. E. (2018). *Digital Image Processing*. Pearson, New York, 4 edition.
- Hirschmüller, H. (2008). Stereo processing by semiglobal matching and mutual information. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(2):328–341.
- IBGE ([PREENCHER]). Censo demográfico: características gerais da população, religião e pessoas com deficiência. Instituto Brasileiro de Geografia e Estatística, Rio de Janeiro. Edição de [PREENCHER].
- Jocher, G., Chaurasia, A., and Qiu, J. (2023). YOLO by ultralytics (versão 8). Software disponível em <https://github.com/ultralytics/ultralytics>.
- Min, D., Choi, S., Lu, J., Ham, B., Sohn, K., and Do, M. N. (2014). Fast global image smoothing based on weighted least squares. *IEEE Transactions on Image Processing*, 23:5638–5653.
- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66.
- Szeliski, R. (2022). *Computer Vision: Algorithms and Applications*. Springer, Cham, 2 edition.
- Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(11):1330–1334.

Anexo A – Parâmetros configuráveis do sistema

Os parâmetros a seguir concentram o comportamento ajustável do sistema e são reunidos para permitir a reprodução dos resultados. **Calibração:** tabuleiro 8×6 com quadrados de 30 mm; 27 pares; refinamento sub-pixel em janela 11×11 (30 iterações ou erro < 0,001); captura em 640×480; *baseline* de 60 a 70 mm; parâmetros em `stereo_calibration_data.xml`. **StereoSGBM:** `minDisparity = 0`; `numDisparities = 128`; `blockSize = 9`; $P_1 = 8 \cdot 3 \cdot 9^2 = 1944$; $P_2 = 32 \cdot 3 \cdot 9^2 = 7776$; `displ2MaxDiff = 1`; `uniquenessRatio = 10`; `speckleWindowSize = 100`; `speckleRange = 32`; `preFilterCap = 63`; modo SGBM_3WAY; divisão da saída por 16 para recuperação sub-pixel. **Filtro WLS** (opcional, requer `opencv-contrib`): $\lambda = 8000$ e $\sigma_{\text{cor}} = 1,5$. **Profundidade:** $Z = fB/d$ calculado apenas onde $d > 0$, com f lido de $Q[2, 3]$ e B de $|1/Q[3, 2]|$; valores superiores a 10 000 mm zerados como inválidos; armazenamento em `uint16`. **Detecção:** `yolov8n.pt` (3,2 milhões de parâmetros); limiar de confiança de 0,5; *whitelist* de 30 classes COCO assistivas; distância pela mediana dos valores válidos de um bloco 11×11 centrado na caixa, com 0 sinalizando ausência de leitura válida. **Grade de proximidade:** passo de 20 px em x e em y ; início em $y = 40$ e $x = 20$ para evitar artefatos de borda; limiar de bipe em 500 mm. **Desnível de piso:** região a partir de 67% da altura; faixa válida de 0 a 6000 mm; $\alpha = 0,05$; multiplicador de vão 1,5; razão suspeita 0,25. **Áudio:** fila de três mensagens com descarte da mais antiga; *cooldown* global de 3 s e por objeto; intervalo mínimo de 1,5 s entre bipes; bipe de 600 Hz e 80 ms; fala a 180 palavras por minuto; *watchdog* de 20 s; cadeia de *backends* `pyttsx3` → SAPI5 → PowerShell System.Speech → `espeak`. **Alerta falado:** < 500 mm, “muito perto”; 500–1000 mm, “cuidado” com distância; > 1000 mm, rótulo com distância; leitura inválida, rótulo seguido de “à frente”. **Gravação:** 2 FPS, com rótulo selecionável pelas teclas 1–5.